Aluno: *Sérgio Luciano de Oliveira Soares*

RA: *263560*

Faculdade de Tecnologia

Relatório para disciplina FT077A - Processamento de Alto Desempenho.

Prof. André Leon S. Gradvohl, Dr.

07/05/2021

SUMÁRIO

1. INTRODUÇÃO

Com base no problema proposto anteriormente realizado no laboratório 01 em PThreads e agora utilizando a mesma otimização de códigos em OpenMp, o mesmo consiste em criar um programa serial e um programa paralelo com OpenMP que calcule a operação matricial D = A * B + C, onde todas as matrizes (A, B, C e D) têm dimensões n x n.

2. METODOLOGIA

Para esse exercício foi realizado apenas as adequações do programa desenvolvido anteriormente em PThreads reutilizando-se todas as otimizações e procedimentos que já haviam sido desenvolvidas no trabalho anterior, entretanto utilizando os recursos solicitados da tarefa 02 em OpenMP.

3. DESENVOLVIMENTO

Otimizações utilizadas para o cálculo:
D = A*B+C = C+A*B

soma de matrizes: $s_{ij} = a_{ij} + b_{ij}$
multiplicação de matrizes: $m_{ik} = a_{i1} . b_{1k} + a_{i2} . b_{2k} + ... + a_{in} . b_{nk}$

Para o cálculo do resultado D (=A*B+C), temos a fórmula para cada elemento:
$D_{ik} = C_{i1} + A_{i1} . B_{1k} + A_{i2} . B_{2k} + ... + A_{in} . B_{nk}$

A matriz foi alocada em uma única etapa (como um vetor).

O acesso aos elementos para o loop acima (1..n) causa o acesso aos elementos em B de forma não sequencial na memória.

Como o acesso a posições próximas de memória são mais interessantes, foi utilizada a abordagem de calcular a matriz transposta de B, de forma que o loop cause o acesso aos elementos de B de forma sequencial, assim como em A.

Bt = transposta de B

Com isso, temos:

$D_{ik} = C_{i1} + A_{i1} . B_{k1} + A_{i2} . B_{k2} + ... + A_{in} . B_{kn}$

Essa abordagem permitiu que o cálculo fosse feito sem que fossem criadas condições de corrida, com apenas a necessidade de uma barreira.

Se tivesse sido calculado A*B para a matriz inteira e depois calculado (A*B)+C, haveria necessidade da criação das threads duas vezes (uma para a multiplicação, e outra para a adição), com o uso de uma barreira para cada etapa.

O uso da diretiva *collapse* foi dispensado uma vez que o programa desenvolvido anteriormente já implementava um laço único para tratar a matriz por elementos de forma sequencial, independente da linha e coluna do elemento, ao invés de tratar a matriz com um laço para as linhas e outro para as colunas.

O código apenas foi alterado para eliminar o controle de carga para cada thread que era realizado, passando a implementar apenas um laço com todos os elementos da matriz.

A função de cálculo foi duplicada no código apenas para garantir que no cálculo sequencial (1 thread) não houvesse sobrecarga gerada pelas diretivas do *OpenMP* com a definição de uma única thread (*num_threads(1)*).

O código todo foi feito em um único arquivo (exerc2_OpenMP.c).

Para compilação:

gcc -fopenmp exerc2_OpenMP.c -o exerc2_OpenMP

https://github.com/s263560/pad/blob/master/OpenMP/exerc2_OpenMP.c

A validação do algoritmo foi feita com n=10, com 3 threads, pegando as matrizes produzidas pelo programa e refazendo o cálculo no excel, com o resultado do programa ficando exatamente igual ao cálculo executado no excel.

4. RESULTADOS E GRÁFICOS

A implementação do paralelismo com o *OpenMP* no código foi bem mais simples que a implementação inicial feita com *pthreads*, uma vez que foi necessário apenas o uso de duas diretivas para paralelizar o laço principal do programa, sem a necessidade de realizar o cálculo de distribuição de carga para cada thread, como havia sido feito no programa anterior.

Calcule o tempo de execução do programa serial para matrizes de tamanho n x n, onde n = 10, 100 e 1000.

Calcule o tempo de execução do programa paralelo para matrizes de tamanho n x n, onde n = 10, 100 e 1000, cada uma com 2, 4, 8, 16 e 32 threads.

Tempos de execução em microssegundos:

	Threads					
n	Serial	2	4	8	16	32
10	7	56	72	156	291	520
100	3.513	2.672	1.011	2.413	1.249	1.709
1000	3.381.772	1.711.305	866.334	864.944	879.532	872.504

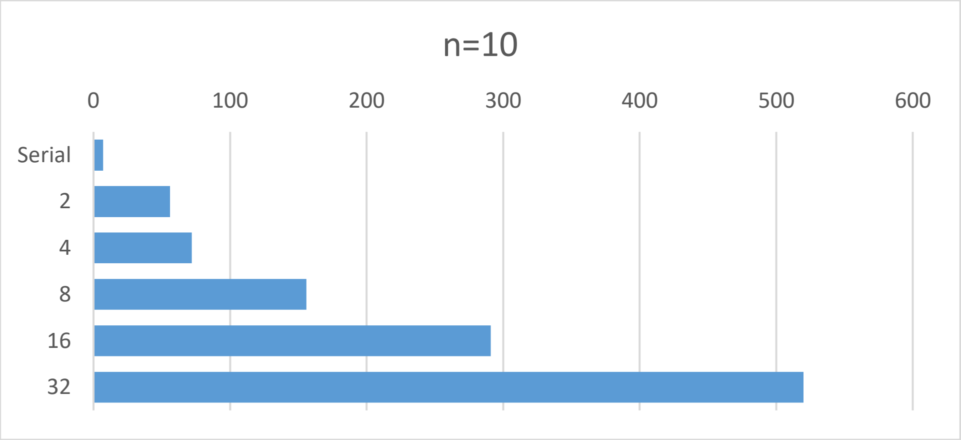

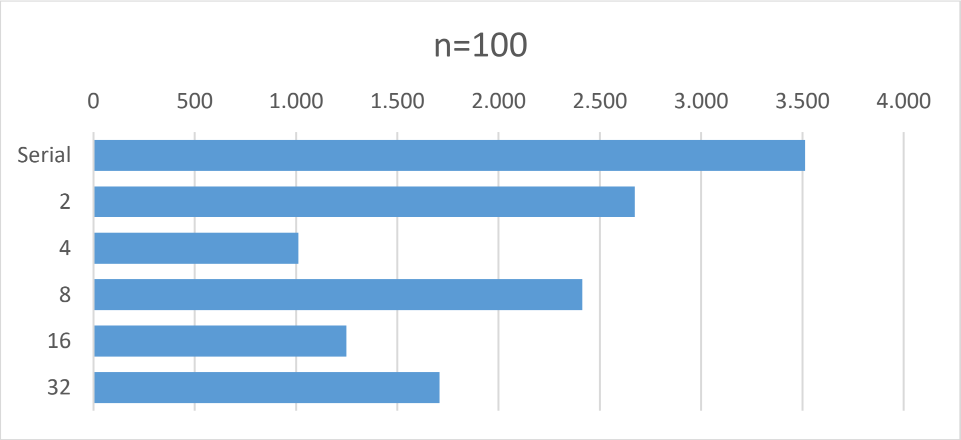

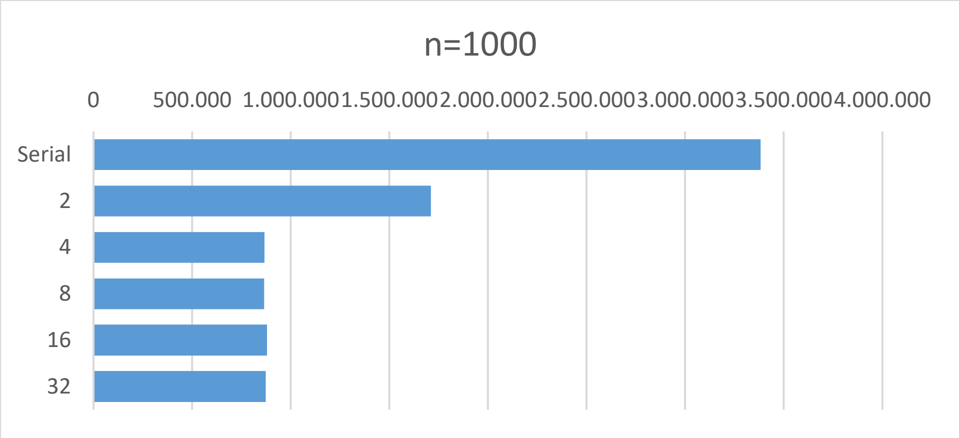

5. **Respostas solicitadas**

Há necessidade de sincronização entre as threads para resolver as operações?

Não. Do modo como o algoritmo foi implementado, não existem condições de corrida, não necessitando então do uso da diretiva *reduction*. Apenas foi necessária a barreira para aguardar a execução de todas as threads, implementada automaticamente pela diretiva *parallel* do OpenMP.

Qual foi o speedup em relação ao programa serial em cada uma das execuções?

Speedup:

	Threads				
n	2	4	8	16	32
10	0,13	0,10	0,04	0,02	0,013
100	1,31	3,47	1,46	2,81	2,06
1000	1,98	3,90	3,91	3,84	3,88

Houve algum caso em que não houve speedup em relação ao programa serial? Se houve, qual a razão para isso?

Sim.

Para n=10, não houve speedup (speedup<1) em nenhuma situação.

A razão é que a quantidade de processamento para o cálculo do resultado é menor que o overhead de criação e controle das tarefas.

Para n=100, esse overhead tornou-se maior a partir do uso de 8 threads, onde o tempo de overhead passou a estar equilibrado com o tempo ganho pelo uso de mais threads, causando resultados de speedup que não estão diretamente proporcionais à quantidade de threads utilizadas – nem para mais, nem para menos.

Para n=1000, o speedup se manteve constante a partir de 4 threads, provavelmente por ter atingido o limite de threads reais que o host podia executar simultaneamente.

6. OBSERVAÇÕES

Para resolver tal exercicio com segurança precisei das aulas 1 e 2, porem apenas as diretivas apresentadas na aula 1 foram utilizadas para a implementação.